



ACADEMIA DE STUDII ECONOMICE BUCUREȘTI
FACULTATEA DE CIBERNETICĂ STATISTICĂ ȘI
INFORMATICĂ ECONOMICĂ

Lucrare de licență

Coordonator științific:

Conf. dr. Anamaria Aldea

Student:

Iulian-Cristinel Rusu

București

2024



**ACADEMIA DE STUDII
ECONOMICE BUCUREȘTI**

**FACULTATEA DE
CIBERNETICĂ STATISTICĂ ȘI
INFORMATICĂ ECONOMICĂ**



Analiza pieței auto la nivel mondial - Studiu de caz folosind R

Coordonator științific:

Conf. dr. Anamaria Aldea

Student:

Iulian-Cristinel Rusu

București

2024

Cuprins

Introducere	1
Capitolul 1. Utilizarea statisticii descriptive și modele pe serii de timp.....	2
1.1. Stadiul actual al cercetării în vederea aplicării modelelor pe diferite industrii	2
1.2. Noțiuni Teoretice	6
1.2.1. Analiza Statistică Descriptivă	6
1.2.2. Modele de Serii de Timp	7
Capitolul 2. Analiza Companiilor din Industria Auto Utilizând Statistica Descriptivă și Modele de Prognoză de Serii de Timp	11
2.1 Analiza Statistică Descriptivă.....	11
2.1.1 Date	11
2.1.2 Rezultate empirice.....	11
2.2 Prognoza Indicilor pe Piață cu Modele de Serii de Timp.....	16
2.2.1 Date	16
2.2.2 Rezultate empirice.....	16
2.2.3 Prognoza indicilor de piață ale companiilor utilizând modelele optime identificate	
31	
2.2.4 Limitări și recomandări	36
Concluzii	38
Bibliografie	39
Anexă	42

Introducere

Lucrarea de față se concentrează pe analiza și prognoza performanțelor financiare și operaționale ale cinci companii majore din industria auto: Volkswagen AG, Toyota Motor Corporation, Hyundai Motor Company, Ford Motor Company și General Motors Company. Într-un context economic dinamic și competitiv, înțelegerea performanțelor acestor companii și anticiparea evoluțiilor viitoare sunt esențiale pentru investitori, manager și toți cei implicați în industria auto.

Industria auto reprezintă unul dintre pilonii fundamentali ai economiei globale, având un impact semnificativ asupra producției industriale, ocupării forței de muncă și inovații tehnologice. Prin adoptarea tehnologiilor avansate și a inovațiilor în producția de vehicule electrice și autonome, industria auto joacă un rol crucial în tranziția către o economie sustenabilă și în reducerea emisiilor de carbon la nivel global.

Prin aplicarea metodelor de statistică descriptivă și a modelelor de serii de timp, această lucrare își propune să ofere o perspectivă detaliată asupra dinamicii financiare a companiilor analizate, evidențiind tendințele și fluctuațiile istorice, precum și anticipând evoluțiile viitoare.

Lucrarea se structurează pe două obiective generale. Primul este evaluarea performanțelor financiare și operaționale ale companiilor auto folosind statistica descriptivă, iar al doilea obiectiv este prognozarea prețurilor acțiunilor companiilor utilizând modele de serii de timp.

Această lucrare aduce o contribuție semnificativă la literatura de specialitate prin aplicarea metodelor statistice pentru analiza și prognoza performanțelor financiare în industria auto. Rezultatele obținute sunt relevante pentru investitori, manageri și analiști financiari, oferind informații valoroase pentru luarea deciziilor strategice și operaționale.

Capitolul 1. Utilizarea statisticii descriptive și modele pe serii de timp

1.1. Stadiul actual al cercetării în vederea aplicării modelelor pe diferite industrii

Analiza performanței financiare și de piață a companiilor din industria auto se face pe baza unor tehnici de analiză descriptivă și modele de serii de timp pentru a înțelege și prezice comportamentele economice. Metodele enunțate joacă un rol important în interpretarea datelor și în generarea de prognoze precise. În acest subcapitol voi oferi o revizuire a literaturii științifice care aplică aceste metode în diverse domenii, cu scopul de a extrage lecții și bune practici care pot fi aplicate în analiza companiilor auto.

Utilitatea statisticilor descriptive poate avea un rol foarte important în interpretarea unui set de date, cum ar fi în cazul evaluării ciclului de viață (LCA) al materialelor de construcții. Împreună cu analiza factorială, pe lângă statistica descriptivă, Grant, et al. (2016) au determinat scopul ca fiind de a oferi o sumarizare a datelor și o perspectivă asupra validității interne, ceea ce îmbunătățește interpretarea rezultatelor. Datele analizate au fost colectate din diverse surse pentru combinațiile de învelișuri de clădiri la Universitatea din Florida. Studiul a arătat că statisticile descriptive au măsurat valorile minime, maxime, medii, deviația standard, coeficientul de asimetrie și coeficientul de boltire. Analiza factorială a descompus datele în nouă variabile, inclusiv impactul cumulativ al ciclului de viață, înlocuiri majore și minore, reparații majore și minore și transportul total.

În cadrul industriei auto, modelele pe serii de timp se pot aplica pentru a identifica cele mai eficiente metode pe diverse categorii de cereri. Un prim exemplu este analizarea cererii de piese de schimb într-o companie transnațională din Mexic (Vargas & Cortés, 2017). Datele utilizate au fost colectate pe o perioadă de 10 ani și au inclus cererea lunară de piese de schimb. Scopul a fost de a compara diferite metode de serie temporală, precum modele clasice de medii mobile, modele autoregresive integrate de medie mobilă (ARIMA), rețele neuronale artificiale (ANN) și modele hibride ARIMA-ANN. Modelele hibride au prezentat o performanță bună în perioadele de eșantion, dar nu la fel de stabilă în perioadele post-eșantion comparativ cu modele ARIMA. Performanța MAPE a fost îmbunătățită de la 57% la 32.65%. Modelele ARIMA au fost cele mai constante în perioadele post-eșantion, arătând o capacitate mai bună de adaptare la schimbările de comportament ale cererii.

Aceste modele au fost aplicate, de asemenea, pentru cererea de vehicule comerciale. Studiul (Toppur, et al., 2023) a fost realizat pentru a anticipa cererea viitoare și pentru a optimiza planificarea producției în contextul incertitudinilor economice globale. Perioada de studiu a inclus date din 2000 până în 2020, cu o atenție deosebită asupra crizei financiare globale din 2008. Datele de producție a vehiculelor comerciale de la un important producător indian au fost analizate utilizând medii mobile, netezire exponențială, descompunere sezonieră și modele ARIMA. Modelul din urmă, ARIMA(0,1,1) a prezis eficient scăderea sectorială care a coincis cu criza din 2008. Metoda de netezire exponențială dublă a prognozat mai bine perioada perturbată decât metodele de medii mobile. Metodologia Box-Jenkins, deși mai complexă, a prezis bine scăderea veniturilor companiei folosind criterii de comparare a modelelor precum criteriul de informație Akaike (AIC) și criteriul de informație Bayesian Schwartz (BIC).

La nivelul consumului de energie, am extras două studii care folosesc modele de serii de timp pentru a captura dinamica datelor. Primul studiu (Trull, et al., 2021) a analizat consumul de energie în cadrul procesului de galvanizare la cald a oțelului, utilizat pe scară largă în industria auto pentru protecția împotriva coroziunii. Datele utilizate au fost colectate în regiunea Basque Country din Spania și au acoperit o perioadă extinsă, detaliile exacte ale perioadei de studiu nefiind specificate în rezumat. Studiul a arătat că modelele ARIMA și Holt-Winters, atunci când sunt combinate cu sezonalități discrete (DIMS), oferă o creștere substanțială a acurateții prognozelor de consum energetic. Modelele de rețele neuronale au arătat performanțe bune în capturarea sezonalităților complexe și neregulate.

Al doilea studiu (Modise, et al., 2021) a cercetat impactul pe termen lung al consumului ridicat de energie în sectorul de producție, care duce la efecte adverse asupra mediului. Datele analizate sunt din perioada 2016 și 2018 de la o companie de producție de componente auto din Africa de Sud. Scopul a fost de a evalua, modela și valida erorile de date generate de electricitate pentru a prezice viitorul consum de energie și emisiile de carbon. Modelul ARIMA cu erori corelate prin regresie în estimarea celor mai mici pătrate generalizate a prezis valori de prognoză pe cinci ani, validând rezultate cu un RSS (Suma Reziduurilor Pătrate) ce arată o îmbunătățire de 89.61% în AR și 99.1% în MA când sunt combinate și un RMSE de 449,8932 la un nivel de încredere 95%.

Pandemia de COVID-19 a avut efecte profunde și fără precedent asupra economiilor și sistemelor de sănătate din întreaga lume. Această perioadă a generat o nevoie urgentă de metode robuste de prognoză pentru a ajuta la luarea deciziilor în timp real. Studiul (Güngör, et al., 2021) a investigat efectele pandemiei de COVID-19 asupra consumului de benzină în Turcia. Setul de date zilnice utilizate acoperă perioada 2014-2020 și a fost obținut din surse naționale de energie.

Scopul a fost de evalua performanța prognozelor modelului ARIMA înainte și după pandemie și de a înțelege dinamica volatilității consumului. Studiul a constatat că modelele standard ARIMA nu au reușit să prognozeze corect consumul post-pandemic, subliniind necesitatea utilizării modelelor care includ volatilitatea pentru a îmbunătăți acuratețea prognozelor.

Într-un alt exemplu, cercetările lui Perone (2022) au utilizat modelele SARIMA pentru a prognoza decesele cumulate cauzate de COVID-19 în 12 țări mari, grav afectate în perioada 21 august 2021 – 19 septembrie 2021. Studiul a demonstrat că modelele SARIMA au fost superioare modelelor ARIMA, datorită capacității lor de a captura sezonabilitatea și de a oferi prognoze mai precise. Modelele SARIMA au depășit modelele ARIMA în 95,8% din toate măsurile de precizie a prognozelor, sugerând un model sezonier clar în date.

Un exemplu de prognoză necesară în perioada pandemică este prognozarea tendințelor cazurilor de COVID-19 în timpul celui de-al treilea val al pandemiei în Malaezia. Studiul (Tan, et al., 2022) folosește datele zilnice privind numărul de cazuri de la ianuarie 2020 până la 5 septembrie 2021, de pe site-ul oficial al Ministerului Sănătății din Malaezia. Modelul SARIMA (1,2,1)(2,0,0) a fost identificat ca fiind cel mai eficient în capturarea sezonității și în prognozarea tendințelor viitoare ale cazurilor COVID-19. Performanța modelului a fost evaluată folosind criterii de informație AIC și BIC, precum și prin metrici de eroare Root Mean Squared Error (RMSE) și Mean Absolute Error (MAE), sugerând o tendință descendentă a cazurilor în perioada prognozată.

Cercetarea a utilizat modele SARIMA și NARNN (Rețea Neurală Autoregresivă Non-Lineară) pentru a prognoza numărul de noi pacienți internați într-un spital public din China. Datele lunare au fost colectate din ianuarie 2010 până în octombrie 2016, iar datele zilnice din ianuarie 2016 până în octombrie 2016. Modelul hibrid SARIMA-NARNN a oferit o acuratețe superioară comparativ cu modelele individuale SARIMA și NARNN pentru datele lunare, dar nu a adus îmbunătățiri semnificative pentru datele zilnice. Modelul SARIMA-NARNN a avut cele mai mici valori ale RMSE, MAE și MAPE (Mean Absolute Percentage Error) în fazele de modelare și testare pentru datele lunare (Zhou, et al., 2018).

Într-un context epidemiologic, studiul (Wang, et al., 2018) a utilizat modelul SARIMA pentru a analiza și prognoza incidența tuberculozei în China. Datele lunare utilizate în analiză au fost preluate de la Centrele pentru Controlul și prevenirea Bolilor, pentru perioada 2005-2017. Studiul a demonstrat o tendință descendentă a ratei de notificare a tuberculozei și a evidențiat importanța utilizării modelelor SARIMA pentru a capta sezonabilitatea și a îmbunătăți predicțiile epidemiologice. Modelul SARIMA identificat a fost ARIMA (0,1,1)(0,1,1). Modelul combinat SARIMA-GRNN (Rețea Neurală Generalizată cu Rețea de Regresie) a avut o performanță

superioară, cu un coeficient de determinare de 0,94 comparativ cu 0,73 pentru modelul SARIMA simplu.

Modelele GARCH (Generalized Autoregressive Conditional Heteroskedasticity) sunt utilizate pentru a modela și a prognoza volatilitatea în seriile temporale financiare. Cazul (Yaziz, et al., 2019) a analizat performanța modelelor ARIMA combinate cu modele simetrice GARCH pentru prognoza prețului aurului în Malaezia. Datele zilnice utilizate au fost colectate în perioada 2003-2014. Studiul a arătat că modelul ARIMA(0,1,0) combinat cu modelul standard GARCH(1,1) folosind inovații t a fost cel mai eficient în gestionarea volatilității și a oferit prognoze precise pentru prețul aurului.

De asemenea, Hussin, et al. (2021) a folosit GARCH, împreună cu ARIMA, pentru modelarea și prognozarea vitezei vântului în Peninsula Malaysia. Perioada analizată este zilnică, în perioada 1990-2014 și au fost organizate adunându-le de la 18 stații meteorologice. Modelul ARIMA a fost utilizat pentru a modela seriile temporale de viteză a vântului. Testul Ljung-Box a fost aplicat pentru a detecta autocorelația serială, iar testul Engle's Lagrange Multiplier (LM) a fost folosit pentru a investiga efectul ARCH în reziduurile modelului. Trei stații au arătat o bună potrivire cu modelul ARIMA, în timp ce modelul ARIMA-GARCH a capturat caracteristicile neliniare ale seriilor temporale de viteză a vântului pentru celelalte stații. Aceste modele au fost evaluate folosind RMSE și MAPE pentru măsurarea acurateței prognozelor.

Compararea performanțelor modelelor ARIMA și SARIMA, alături de LSTM (Long Short-Term Memory) în prognoza profitului a fost realizată de Sirisha, et al. (2022). Datele istorice utilizate în analiză au fost colectate de la Manipal Institute of Technology, India, pentru perioada 1972-2017. Studiul a arătat că modelul LSTM a avut cea mai bună performanță, obținând o acuratețe de aproximativ 97.01%, urmat de modelul SARIMA cu 94.378% și de modelul ARIMA cu 93.84%. Rezultatele prognozelor pentru următorii cinci ani au indicat că modelul LSTM depășește ambele modele statistice în ceea ce privește acuratețea predicțiilor.

Lucrarea a analizat volatilitatea prețului țițeiului și impactul său asupra economiilor globale, cu un accent special pe economiile Europei și Statelor Unite. Datele lunare sunt de la U.S. Energy Information Administration și Federal Reserve Economic Data (FRED) din ianuarie 2017 până în septembrie 2021. Studiul a arătat că modelele ARIMA au obținut indicatori de acuratețe mai buni decât modelele SARIMA în prognozarea prețurilor țițeiului atât în Europa, cât și în Statele Unite. Valoarea MAPE a fost de 0,05 pentru modelele ARIMA în ambele regiuni, indicând o acuratețe ridicată (Lee, et al., 2022).

Nu în ultimul rând, de-a lungul timpului, modelele de machine learning și deep learning, precum GRU (Gated Recurrent Units) și LSTM, au devenit din ce în ce mai eficiente, în

comparație cu metodele statistice tradiționale, cum ar fi ARIMA și SARIMA (ArunKumar, et al., 2022). Studiul a fost făcut pe 10 țări puternic afectate de pandemie: SUA, Brazilia, India, Rusia, Africa de Sud, Mexic, Peru, Chile, Marea Britanie și Iran. Evaluarea modelelor a fost realizată pe baza MSE și RMSE. Pentru majoritatea seturilor de date analizate, modelele bazate pe deep learning (GRU și LSTM) au depășit performanțele modelelor statistice (ARIMA și SARIMA) în termeni de RMSE, cu valori de 40 de ori mai mici pentru GRU comparativ cu ARIMA. Cu toate acestea, în anumite cazuri, modelele statistice au oferit predicții mai precise. Modelele SARIMA au arătat o performanță superioară în captarea sezonality datelor, iar modelele GRU și LSTM au demonstrat o abilitate superioară în gestionarea datelor neliniare. Modelele statistice rămân relevante, în special în situațiile în care datele prezintă caracteristici sezoniere puternice.

1.2.Noțiuni Teoretice

Metodologia asigură un cadru clar pentru colectarea și analiza datelor. În acest capitol, voi explora atât analiza statistică descriptivă cât și modelele de serii de timp, oferind detalii despre fiecare metodă și tehnică utilizată, precum și testele statistice aplicate pentru validarea rezultatelor.

Informațiile au fost redactate cu ajutorul următoarelor cărți: (Salvatore & Reagle, 2002), (Chapman & Feit, 2015), (Brooks, 2008), (Cowpertwait & Metcalfe, 2009).

1.2.1. Analiza Statistică Descriptivă

Statistica descriptivă este utilizată pentru a rezuma și descrie caracteristicile esențiale ale datelor, ajutând la identificarea tendințelor, variabilității și relațiilor dintre variabile. Acesta include măsurile de tendință centrală, măsurile de dispersie, coeficienții de asimetrie și boltire, precum și vizualizarea datelor.

1.2.1.1. Măsurile de Tendință Centrală

- Media (\bar{x}): Media aritmetică este calculată ca suma tuturor valorilor împărțită la numărul de observații.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

unde n este numărul total de observații, iar x_i reprezintă valoarea fiecărei observații.

- Mediana: Mediana este valoarea care împarte setul de date în două părți egale. Dacă numărul de observații este impar, mediana este valoarea mijlocie. Dacă este par, mediana este media celor două valori din mijloc.

- Modul: Modulul este valoare care apare cel mai frecvent într-un set de date.

1.2.1.2. Măsurile de Dispersie

- Varianța (σ^2): Varianța măsoară dispersia datelor față de media lor. Abaterea standard (σ) este rădăcina pătrată a varianței.

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

(2)

- Coeficientul de Variație (CV): Coeficientul de variație exprimă abaterea standard ca procent din media.

$$CV = \frac{\sigma}{\bar{x}} \times 100$$

(3)

1.2.1.3. Coeficienții de Asimetrie și Boltire

- Coeficientul de Asimetrie: Asimetria măsoară simetria distribuției datelor. Un coeficient de asimetrie pozitiv indică o distribuție cu coada mai lungă la dreapta, în timp ce un coeficient negativ indică o coadă mai lungă la stânga. O valoare aproape de zero indică o distribuție simetrică.

$$Asimetrie = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^3$$

(4)

- Coeficientul de Boltire: Boltirea măsoară înălțimea unei distribuții. Un coeficient de boltire pozitiv indică o distribuție cu cozi mai groase și un vârf mai înalt, în timp ce un coeficient negativ indică o distribuție plată cu cozi mai subțiri.

$$Boltire = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)}$$

(5)

1.2.2. Modele de Serii de Timp

Modelele de serii de timp sunt utilizate pentru a analiza și a prognoza datele care sunt colectate în ordine cronologică. În această secțiune, voi discuta metodologia Box-Jenkins și

modelele ARIMA, SARIMA, ARCH și GARCH, utilizate pe scară largă în analizele economice și financiare.

1.2.2.1. Metodologia Box-Jenkins

Metodologia Box-Jenkins este un proces iterativ utilizat pentru identificarea, estimarea și diagnosticarea modelelor ARIMA și SARIMA. Acesta include următorii pași:

- Se realizează graficul seriei pentru a observa în prealabil semne ce trădează nestăționaritatea acesteia (trend, sezonalitate, etc.).
- Ajustarea sezonieră în cazul în care este necesar (se va folosi ajustarea sezonieră STL).
 - STL (Seasonal and Trend decomposition using Loess) este utilizată pentru a descompune seriile temporale în componente sezoniere, tendință și erori. Aceasta ajută la eliminarea efectelor sezoniere și la obținerea unei serii mai netede pentru analiză.
- În cazul în care seria este nestăționară, verificând cu ajutorul testului ADF pentru staționarizare, se va staționariza prin diferențierea acesteia și se verifică din nou testul.
 - Testul ADF (Augmented Dickey-Fuller) este utilizat pentru a testa staționaritatea unei serii temporale. Ipotezele testului sunt:

H_0 : seria admite o rădăcină unitară și este nestăționară

H_1 : seria nu admite o rădăcină unitară și este staționară

- Se determină parametrii din cadrul modelului ARIMA(p,d,q)/SARIMA(p,d,q)(P,D,Q)
- Se testează caracteristicile modelelor alese și se alege cel mai potrivit model pe baza unor criterii de performanță precum AIC și BIC sau măsuri de eroare (MAE, RMSE, MAPE, etc.).
- Se efectuează analiza și prognoza dorite, cu ajutorul modelului final.

Modelul Autoregressive Integrated Moving Average (ARIMA) combină trei componente: autoregresie (AR), diferențiere (I) și medie mobilă (MA). Modelul ARIMA(p,d,q) este exprimat ca:

$$\phi_p(B)(1-B)^d y_t = \theta_p(B)\epsilon_t$$

(6)

unde:

y_t este valoarea seriei la momentul t ,

$\Phi_p(B)$ este un polinom de ordine p în operatorul de decalaj B ,

$(1-B)^d$ reprezintă diferențierea de ordin d ,

$\theta_p(B)$ este un polinom de ordine q în operatorul de decalaj B ,

ϵ_t este eroarea la momentul t ,

Modelul Seasonal ARIMA (SARIMA) extinde ARIMA pentru a include componente sezoniere. Modelul SARIMA(p,d,q)(P,D,Q)_s este definit ca:

$$\Phi_p(B)\Phi_p(B^S)(1-B)^d(1-B^S)^D y_t = \theta_p(B)\theta_q(B^S)\epsilon_t$$

(7)

unde:

$\Phi_p(B^S)$ și $\theta_q(B^S)$ sunt polinoame sezoniere de ordine P și Q ,

s este perioada sezonality,

celelalte componente sunt similare cu cele din modelul ARIMA.

Testul Jarque-Bera este utilizat pentru a testa normalitatea reziduurilor. Ipotezele testului sunt:

H_0 : Reziduurile sunt distribuite normal

H_1 : Reziduurile nu sunt distribuite normal

Testul Ljung-Box este utilizat pentru a testa autocorelarea reziduurilor. Ipotezele testului sunt:

H_0 : Nu există autocorelare în reziduuri

H_1 : Există autocorelare în reziduuri

Testul ARCH LM este utilizat pentru a detecta efectele ARCH în reziduuri. Ipotezele testului sunt:

H_0 : Nu există efecte ARCH în reziduuri (reziduurile sunt homoschedastice)

H_1 : Există efecte ARCH în reziduuri (reziduurile sunt heteroschedastice)

1.2.2.2. Modelele ARCH și GARCH

Modelele ARCH și GARCH sunt utilizate atunci când datele financiare prezintă heteroschedasticitate, adică volatilitate nu este constantă în timp. Aceste modele ajută la captarea și prognozarea acestor schimbări în volatilitate.

Modelul ARCH (Autoregressive Conditional Heteroskedasticity) captează efectele de volatilitate autocorelată. Modelul ARCH(q) este definit ca:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2$$

(8)

unde:

σ_t^2 este varianța condiționată a erorii la momentul t ,

α_0 este o constantă,

ϵ_{t-i}^2 sunt pătratele reziduurilor din perioadele anterioare.

Modelul Generalized ARCH (GARCH) extinde ARCH pentru a include termeni autoregresivi ai varianței condiționate. Modelul GARCH(p,q) este definit ca:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

(9)

unde:

$\beta_j \sigma_{t-j}^2$ sunt termeni autoregresivi ai varianței condiționate.

Capitolul 2. Analiza Companiilor din Industria Auto Utilizând Statistica Descriptivă și Modele de Prognoză de Serii de Timp

În acest capitol, voi analiza performanța financiară și operațională a cinci companii auto majore – Volkswagen AG, Toyota Motor Company, Hyundai Motor Company, Ford Motor Company și General Motors Company, acestea fiind în top 10 cele mai mari companii în funcție de venit în 2023 (Insider Monkey, 2023) . Analiza se va desfășura pe două etape principale, fiecare având un scop specific.

2.1 Analiza Statistică Descriptivă

2.1.1 Date

Prima etapă implică utilizarea statisticii descriptive pentru a analiza datele operaționale colectate din rapoartele anuale ale companiilor în perioada 2000-2023. Aceste date includ numărul de vehicule vândute, exprimate în mii de unități, veniturile, costurile și profiturile, acestea fiind exprimate în miliarde de euro. Prețurile au fost ajustate la inflația din 2023 pentru a asigura comparabilitatea între anii diferiți. Scopul acestei analize este de a oferi o imagine clară și detaliată a performanței istorice a fiecărei companii. Prin aplicarea măsurilor de tendință centrală și de dispersie, precum și a coeficienților de asimetrie și boltire, voi putea identifica tendințele și variabilitatea. Aceasta ne va ajuta să înțelegem mai bine dinamica internă a fiecărei companii și să comparăm performanțele lor relative.

2.1.2 Rezultate empirice

Rezultatele statisticilor descriptive pentru fiecare companie sunt prezentate în Tabelul 1. Acesta este împărțit pe obiectivele analizate, pentru a se putea analiza cu ușurință situațiile companiilor din mai multe perspective. Valorile minime și maxime pentru fiecare variabilă au fost identificate, iar statistici descriptive, precum media, mediana, abaterea standard, coeficientul de variație, coeficientul de asimetrie și de boltire sunt calculate pentru a oferi o imagine de ansamblu asupra performanțelor acestor companii.

Volkswagen AG a avut un număr minim de vehicule vândute în anul 2002, de aproximativ 5 milioane de unități, în mare parte din perioadei de criză precedentă (Volkswagen AG, 2003). De departe cel mai profitabil an din cadrul companiei este 2019, unde aceasta a înregistrat valori maxime în vânzări (11 milioane de unități) și profit (52.3 miliarde EUR), motivul principal fiind

diversificarea produselor și a creșterii globale (Volkswagen AG, 2020). Valorile minime pentru venituri și costuri provin din anul 2008, reflectând dificultățile economice majore (Volkswagen AG, 2009). Profitul atinge pragul minim de -19 miliarde EUR în 2015, an care conține și valorile maxime ale veniturilor și costurilor, în urma scandalului legat de emisiile diesel (Volkswagen AG, 2016). Coeficientul de variație indică o variabilitate mică pentru vânzările companiei, ceea ce înseamnă că valorile sunt în jurul mediei de 7.8 milioane de unități, iar coeficienții pentru restul obiectivelor sunt foarte mari, media nefiind reprezentativă, deoarece datele sunt foarte dispersate. Distribuțiile vânzărilor și profiturilor sunt relativ simetrice, cu valori foarte aproape de 0, ceea ce confirmă diferența mică dintre medii și mediane, contrar cu situația vânzărilor și ale costurilor, unde asimetria este negativă. De asemenea, distribuțiile pe toate cele 4 obiective sunt platycurtice, datorită coeficientului negativ de boltire, astfel nu sunt prezente valorile extreme.

Toyota Motor Corporation a avut cel mai scăzut număr de vehicule vândute în anul 2020, cu aproximativ 5.5 milioane de unități, afectată semnificativ de pandemia COVID-19 (Toyota Motor Corporation, 2021). Cel mai profitabil an este 2015, înregistrând valori maxime la trei din cele patru obiective analizate, venituri, costuri și profit, datorită unei perioade eficientizări a costurilor și a cursului valutar favorabil (Toyota Motor Corporation, 2016). Pierderea de -2.25 miliarde EUR, alături de veniturile și costurile minime, a fost în 2009, influențat de criza financiară globală (Toyota Motor Corporation, 2010). Coeficientul de variație pentru vânzări indică o variabilitate redusă, arătând că valorile sunt destul de concentrate în jurul mediei de 8.8 milioane de unități. În schimb, coeficienții pentru venituri, costuri și profituri sunt mari, sugerând că media nu este reprezentativă din cauza dispersiei mari a datelor. Distribuțiile veniturilor și profiturilor sunt ușor asimetrice pozitive, indicând prezența valorilor mari, în timp ce vânzările și costurile prezintă o asimetrie negativă. Toate distribuțiile sunt platycurtice, reflectând lipsa valorilor extreme.

Hyundai Motor Company a înregistrat cel mai mic număr de vehicule vândute și costuri minime în anul 2000, cu aproximativ 1.6 milioane de unități și 19.71 miliarde EUR, într-o perioadă în care compania încă își construia prezența pe piața globală (Hyundai Motor Company, 2001). Vânzările maxime au fost atinse în 2016, cu 4.9 milioane de unități, datorită expansiunii globale și diversificării produselor (Hyundai Motor Company, 2017). Veniturile și profitul au atins pragul minim în 2008, din cauza impactului crizei financiare (Hyundai Motor Company, 2009), iar anul 2015 a fost cel mai profitabil an, datorită succesului strategiilor de creștere și eficientizare implementate de companie (Hyundai Motor Company, 2016). Media este reprezentativă în cazul vânzărilor, cu un coeficient de variație de 30%, în timp ce în restul obiectivelor, valorile sunt foarte dispersate. Distribuția pentru vânzări este ușor negativă, în timp ce pentru venituri, costuri și

profituri, asimetria este negativă, sugerând prezența de valori mari. Toate distribuțiile sunt platicurtice, reflectând absența valorilor extreme.

Ford Motor Company a avut valoarea minimă de vehicule vândute în 2021, cu aproximativ 4 milioane unități, afectată puternic de perturbările lanțurilor de aprovizionare și scăderea cererii globale (Ford Motor Company, 2022). Vânzările maxime au fost înregistrate în anul 2000, cu 7.4 milioane unități, reflectând o perioadă de expansiune și succes pe piața globală (Ford Motor Company, 2001). Caturile și veniturile minime au fost în 2008, criza financiară având un foarte mare impact asupra companiei (Ford Motor Company, 2009), iar valorile maxime apar în 2015, pe fondul creșterii investițiilor și extinderii operaționale globale (Ford Motor Company, 2016). 2006 a fost cel mai slab an din punctul de profitabilitate, compania înregistrând o pierdere de 24.5 miliarde EUR, fiind evidente problemele financiare și pierderi operaționale (Ford Motor Company, 2007), iar cel mai profitabil an este 2013, datorită strategiilor de eficientizare și redresare implementate de companie (Ford Motor Company, 2014). Coeficienții de variație pentru vânzări indică o variabilitate mică, de 16.56%, sugerând că valorile sunt concentrate în jurul mediei de aproximativ 6 milioane de unități. În schimb, coeficienții pentru venituri, costuri și profituri sunt mari spre foarte mari, însemnând o dispersie mare a datelor. Toate distribuțiile sunt aproape normale, ușor platicurtice, distribuțiile vânzărilor și costurilor sunt ușor asimetrice negative, iar veniturile și profiturile prezintă o asimetrie pozitivă.

General Motors a înregistrat cele mai scăzute vânzări în 2022, cu aproximativ 6 milioane de unități, reflectând provocările continue din lanțurile de aprovizionare și scăderea cererii globale (General Motors Company, 2023). Anul 2016 este cel mai profitabil pentru companie, vânzările, venitul și profitul având valorile maxime în anul menționat, pe măsură ce compania a continuat să se redreseze și să își extindă operațiunile globale (General Motors Company, 2017). Din punctul de vedere al veniturilor, cel mai slab an este 2008, în plină criză financiară, compania înregistrând 102.55 miliarde EUR, iar din punctul de vedere al profitului, în 2012 s-a produs o pierdere de 50 miliarde EUR, datorită efectelor falimentului încă prezente și a problemelor de calitate și rechemări (General Motors Company, 2013). Coeficienții și distribuțiile obiectivelor sunt asemănătoare cu cele ale companiei Ford.

Table 1 Rezultatele statisticilor descriptive pentru fiecare companie
Sursa: Analiză proprie, R Studio 4.2.2

STATISTICĂ DESCRIPTIVĂ	MIN	MEAN	MED	MAX	SD	CV	SKEW	KURT
VEHICULE (mii unități)								
VOLKWAGEN	4996.18	7860.09	8421.15	10956	2215.81	28.19%	-0.04	-1.69
TOYOTA	5526	8784.75	9220.50	11090	1739.4	18.86%	-0.38	-1.34
HYUNDAI	1575	3460.93	3817.37	4914	1149.53	30.11%	-0.33	-1.51
FORD	3942	5972.67	6411.50	7424	989.42	16.56%	-0.61	-0.94
GENERAL MOTORS	5941	8502.04	8606.50	10008	1201.63	14.13%	-0.76	-0.52
VENITURI (miliarde EUR)								
VOLKWAGEN	86.47	398.92	254.72	1011.21	281.54	70.58%	0.79	-0.82
TOYOTA	100.20	359.61	254.24	865.05	206.86	57.52%	0.93	-0.32
HYUNDAI	42.38	131.92	101.83	305	79.37	60.17%	0.74	-0.76
FORD	98.83	309.05	283.50	642.38	134.89	43.65%	0.75	0.14
GENERAL MOTORS	102.55	314.22	313.23	592.92	123.55	39.32%	0.42	-0.12
COSTURI (miliarde EUR)								
VOLKWAGEN	73.40	329.44	216.66	850.45	228.53	69.37%	0.84	-0.69
TOYOTA	102.45	327.29	243.26	778.13	185.19	56.58%	0.97	-0.20
HYUNDAI	19.71	104.30	78.14	244.44	66.83	64.07%	0.70	-0.86
FORD	109.65	304.81	280.25	612.40	129.02	42.33%	0.65	-0.08
GENERAL MOTORS	109.05	311.11	316.02	559.18	114.66	36.86%	0.24	-0.12
PROFITURI (miliarde EUR)								
VOLKWAGEN	-19.29	18.24	15.25	52.28	16.79	92.05%	0.10	-0.63
TOYOTA	-2.25	28.46	21.84	86.92	21.28	74.77%	0.74	0.12
HYUNDAI	1.63	7.71	6.84	21.09	5.15	66.80%	0.84	-0.11
FORD	-24.50	4.24	4.81	30.11	13.29	313.44%	0.07	-0.24
GENERAL MOTORS	-50.21	3.11	7.45	34.52	20.14	647.59%	-1.17	0.98

Analizând performanțele operaționale ale companiilor, se observă că fiecare companie a trecut prin perioade de creștere și declin influențate de factori economici globali, crize financiare și strategii interne de expansiune și eficientizare. Volkswagen și Toyota au demonstrat o performanță solidă pe toate cele 4 obiective, compania Hyundai prezintă o evoluție constantă, fiind de astfel singura companie dintre cele analizate care a obținut un profit pozitiv în timpul crizei financiare din 2008, iar Ford și General Motors au avut probleme majore la începutul anilor 2000, cea din urmă chiar falimentând în 2009 (General Motors Company, 2011), însă cu mai multe restructurări interioare companiilor și expansiuni globale, s-au reimpus pe piața auto, cu toate că acum competiția este mai strânsă ca niciodată.

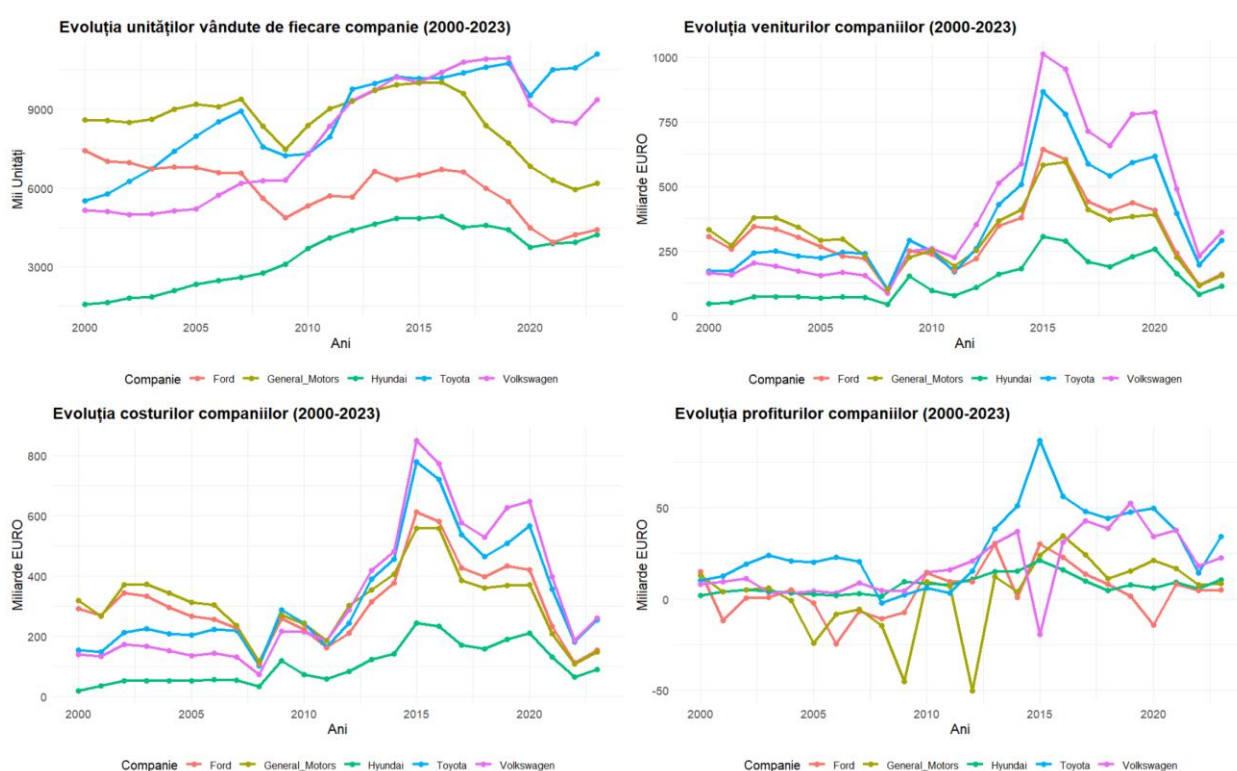


Figure 1 Evoluția fiecărei companii în funcție de obiectivele alese
Sursa: Analiză proprie, R Studio 4.2.2

2.2 Prognoza Indicilor pe Piață cu Modele de Serii de Timp

2.2.1 Date

A doua etapă constă în prognozarea indicilor de piață ai acestor companii utilizând modele de serii de timp, cum ar fi ARIMA, SARIMA și ajustările cu ARCH sau GARCH, dacă este cazul. Datele pentru prognozare sunt prețuri lunare de închidere colectate de pe platforma Yahoo Finance, acoperind perioada ianuarie 2011 – ianuarie 2024, acestea fiind exprimate în moneda EUR. Scopul acestei analize este de a anticipa comportamentele viitoare ale pieței auto și de a oferi previziuni precise privind performanța bursieră a fiecărei companii. Modelele de serii de timp sunt esențiale pentru captarea tendințelor și sezonality din datele financiare și pentru gestionarea volatilității. Astfel, această etapă îmi va permite să ofer recomandări bazate pe date pentru investitori și manageri.

2.2.2 Rezultate empirice

2.2.2.1 Analiza graficelor și identificarea trend-ului și sezonality

Figura de mai jos reprezintă evoluțiile prețurilor acțiunilor pentru cele cinci companii în perioada ianuarie 2011 – ianuarie 2024, pentru a capta evoluțiile acestora pe o perioadă mai lungă de timp. Analiza acestor grafice ne permite să identificăm tendințele pe termen lung, fluctuațiile și sezonality specifică fiecărei companii.

Pentru Volkswagen AG, exceptând o mică scădere în toamna anului 2011, unde Suzuki a încetat să mai colaboreze cu ei (Volkswagen AG, 2012), prețul acțiunii are un trend crescător până în 2015, atunci când scandalul în care Volkswagen a fost descoperit că a instalat un software de manipulare a emisiilor a fost făcut public (Volkswagen AG, 2016), prețul ajungând la aproximativ 60 EUR. Au urmat apoi mai multe fluctuații, până în 2020 când se remarcă din nou scăderea prețului, motivul principal fiind situația pandemică la acea vreme. La începutul anului 2021, prețul companiei a atins un maxim de aproximativ 160 EUR. Creșterea poate fi atribuită de tranziția către vehiculele electrice și anunțurilor de noi modele (Volkswagen AG, 2022), urmând alte fluctuații până la începutul anului 2024, unde prețul pare să crească.

Graficul pentru Toyota Motor Corporation indică o tendință de creștere constantă a prețului acțiunilor pe întreaga perioadă analizată. De la 2011 până în 2024, prețul a urcat de la aproximativ 3 EUR la peste 20 EUR, cu fluctuații minore. Se observă faptul că Toyota a reușit să se adapteze rapid la schimbările pieței și să își mențină un ritm constant de creștere. Prețul maxim a fost atins

la începutul anului 2024, când a depășit 25 EUR, reflectând succesul companiei în inovații și creșterea cererii pentru vehiculele sale (Toyota Motor Corporation, 2024).

Prețul pentru Hyundai Motor Company arată o tendință de creștere până la sfârșitul anului 2014, urmată de o perioadă de stabilitate și fluctuații moderate. După perioada pandemică în care prețul a atins pragul minim din perioada analizată, se remarcă creșterea considerabilă, ajungând să aibă valoarea maximă de 157 EUR în iunie 2021, datorită lansărilor de noi modele populare și expansiunii globale, mai ales în Europa (Hyundai Motor Company, 2022). Hyundai a demonstrat o capacitate remarcabilă de adaptare.

Graficul pentru Ford Motor Company arată o stabilitate a prețului până în 2020, când s-a atins pragul minim în urma perioadei la acea dată. Prețul maxim este prezent în luna decembrie 2021, de 15 EUR, pe fondul restructurărilor interne (Ford Motor Company, 2022).

Evoluția prețului pentru General Motors Company este asemănătoare cu cea a companiei Ford. Excepția este prețul minim care a fost înregistrat în 2011, compania încă fiind în recuperare după falimentul și restructurarea companiei din 2009 și reintrarea la bursa americană în 2010 (General Motors Company, 2011). La fel ca Volkswagen, Hyundai și Ford, pragul maxim al prețului este atins 2021, datorită strategiilor de adaptare la pandemie.

În ceea ce privește sezonabilitatea, acestea apar, în cazul industriei auto, în urma perioadei de lansări de vehicule noi, raportat chiar de compania Ford (2022) și datorită lansării raportărilor financiare. Eliminarea efectelor sezoniere îmi permite să identific mai clar tendințele de bază și să fac prognoze mai precise. Utilizarea metodei de ajustare sezonieră, cum ar fi STL, ar putea îmbunătăți considerabil calitatea analizei și a prognozelor financiare.

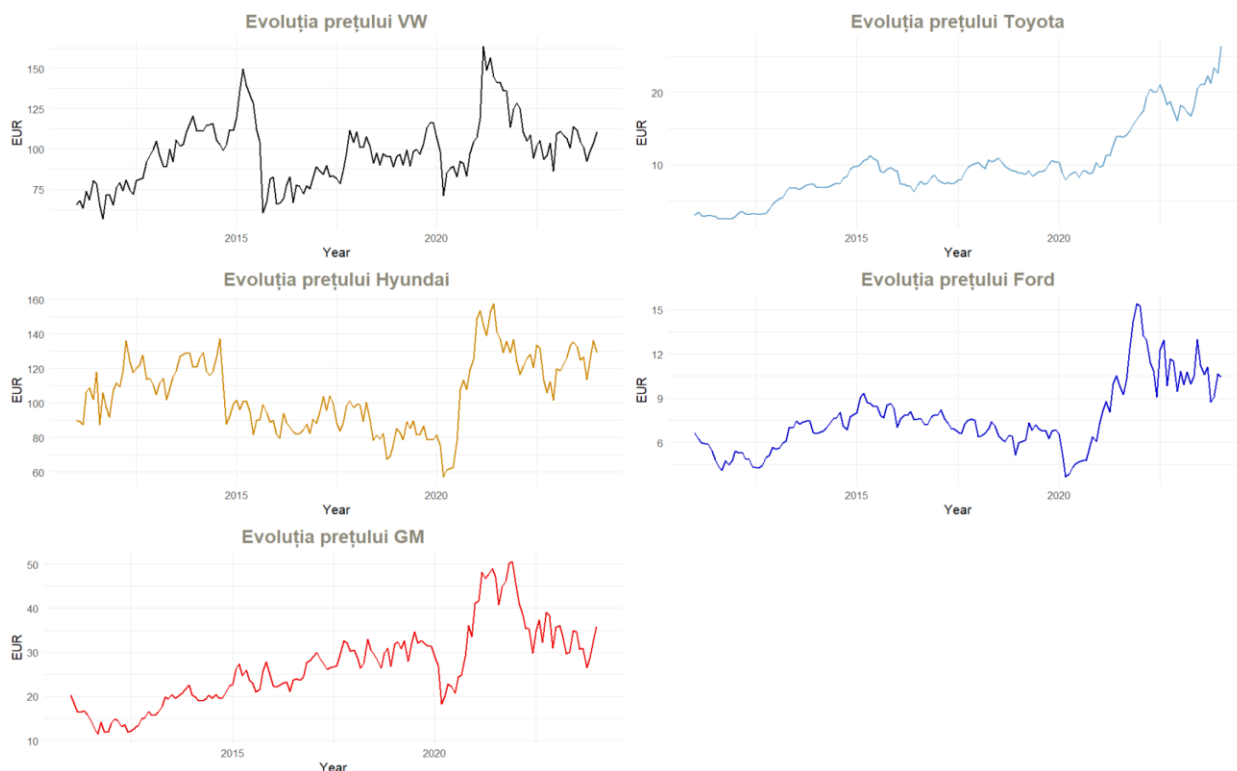


Figure 2 Evoluția prețurilor acțiunilor
Sursa: Analiză proprie, R Studio 4.2.2

2.2.2.2 Ajustarea sezonieră

Figura următoare confirmă faptul că sezonalitatea este prezentă în fiecare din cele 5 companii, în diverse cantități, nealinierea liniilor albastre ce reprezintă media prețurilor pe fiecare lună fiind cel mai mare motiv pentru prezența sezonality. Un lucru ce se poate observa este că toate încep și termină anul cu un preț mai mare al indicelui de piață, ca mai apoi să scadă după luna ianuarie, în diferite proporții pentru fiecare companie. Se va proceda cu desezonalizarea seriilor, pentru a corecta și nivela liniile, utilizând metoda STL.

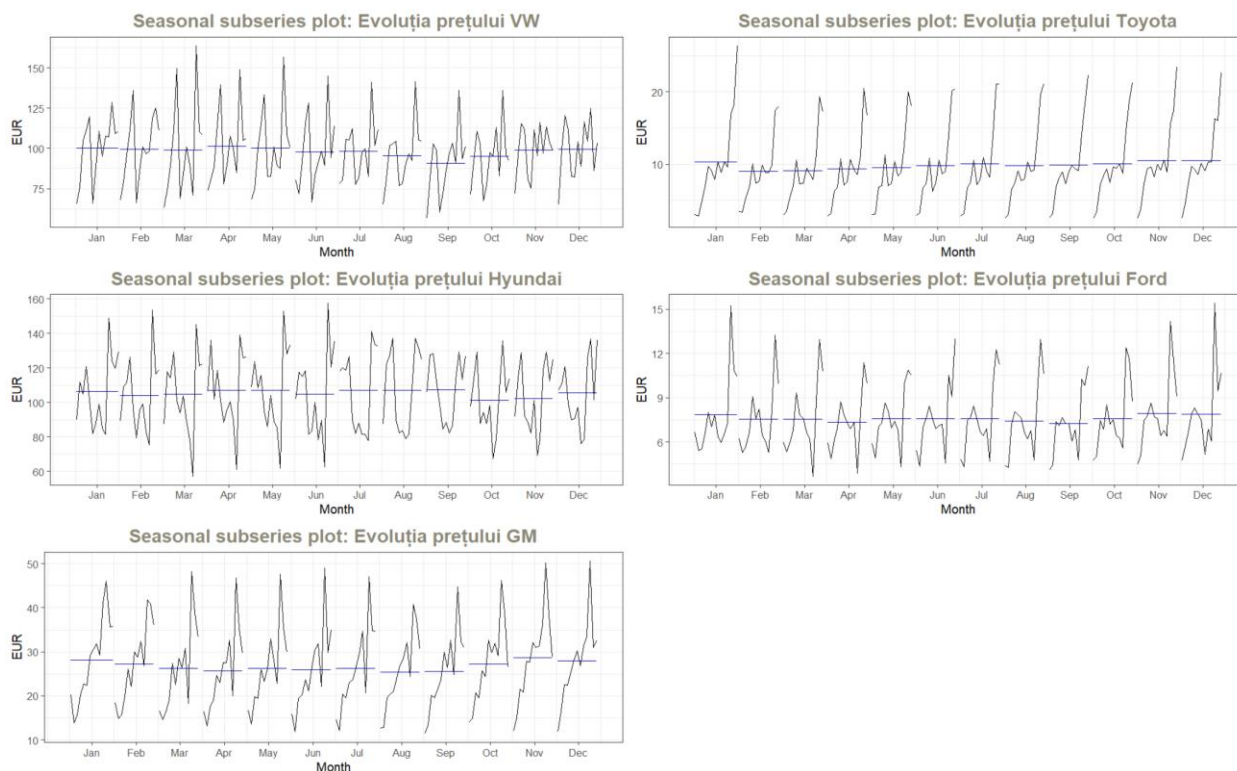


Figure 3 Identificarea sezonaliității fiecărui preț
Sursa: Analiză proprie, R Studio 4.2.2

2.2.2.3 Staționarizarea seriilor

Pentru utilizarea modelelor de tip ARIMA și SARIMA este necesar ca fiecare serie de timp să fie staționară. Pentru a se identifica aceasta, se realizează corelogramele pe seriile ajustate sezonier. După cum se poate remarca, seria de timp Volkswagen este nestaționară ca urmare a prezenței lag-urilor ce se regăsesc în afara intervalului punctat. Dar pentru a fi sigur de acest fapt, voi realiza testul staționarității ADF pentru verificarea proprietății. Se va proceda asemănător și în cazul celorlalte companii.




Figure 4 Corelograma seriei Volkswagen
Sursa: Analiză proprie, R Studio 4.2.2

Tabelul reprezintă rezultatele testului ADF pentru fiecare companie și am realizat pe 3 părți și pe 3 praguri de încredere. Prima parte pe care a fost realizat testul este cea de trend (trend+constantă), unde toate cele cinci companii au valorile în modul ale testului statistic mai mici decât valorile critice în modul, ceea ce rezultă că seriile sunt nestaționare pe trend. De asemenea, acestea sunt nestaționare și pe cazul drift (constantă), doar că Volkswagen este staționară la pragul de 95%. În cele din urmă, pe parte de none (elemente deterministe), Toyota are testul statistic în modul mai mare decât toate cele trei valori critice, ceea ce poate duce la concluzia ca seria este staționară pe partea de elemente deterministe. Cum celelalte 4 serii sunt nestaționare și pe acest tip, pot concluziona că toate sunt majoritar nestaționare. Pentru staționarizare, va fi nevoie să diferențiez o dată fiecare serie și să refac testul pentru a mă asigura că datele sunt staționare.

Table 2 Rezultatele testului ADF pentru seriile nediferențiate
Sursa: Analiză proprie, R Studio 4.2.2

Valori critice				
	t-statistic	1%	5%	10%
trend				
Volkswagen	-3.041	-3.99	-3.43	-3.13
Toyota	-0.0859	-3.99	-3.43	-3.13
Hyundai	-2.4299	-3.99	-3.43	-3.13
Ford	-2.6576	-3.99	-3.43	-3.13
General Motors	-2.9644	-3.99	-3.43	-3.13
drift				
Volkswagen	-2.9243	-3.46	-2.88	-2.57
Toyota	1.6675	-3.46	-2.88	-2.57
Hyundai	-2.4299	-3.46	-2.88	-2.57
Ford	-1.9243	-3.46	-2.88	-2.57
General Motors	-1.6991	-3.46	-2.88	-2.57
none				
Volkswagen	-0.1669	-2.58	-1.95	-1.62
Toyota	2.9527	-2.58	-1.95	-1.62
Hyundai	-0.0651	-2.58	-1.95	-1.62
Ford	-0.1277	-2.58	-1.95	-1.62
General Motors	-0.0036	-2.58	-1.95	-1.62

Diferențierea seriilor de timp duce la concluzia ca acestea devin staționare. Valoarea testului statistic în modul este mai mare decât toate valorile critice în modul, acceptând astfel ipoteza nulă referitoare la staționaritate. Astfel, voi proceda cu estimarea modelului de ARIMA sau SARIMA și ajustarea ARCH sau GARCH, dacă este nevoie, pentru fiecare companie în parte.

Table 3 Rezultatele testului ADF pentru seriile diferențiate de ordin 1
Sursa: Analiză proprie, R Studio 4.2.2

Valori critice				
	t-statistic	1%	5%	10%
trend				
Volkswagen	-9.1568	-3.99	-3.43	-3.13
Toyota	-7.4277	-3.99	-3.43	-3.13
Hyundai	-10.3217	-3.99	-3.43	-3.13
Ford	-10.3764	-3.99	-3.43	-3.13
General Motors	-9.5294	-3.99	-3.43	-3.13
drift				
Volkswagen	-9.17	-3.46	-2.88	-2.57
Toyota	-7.2004	-3.46	-2.88	-2.57
Hyundai	-10.3557	-3.46	-2.88	-2.57
Ford	-10.4078	-3.46	-2.88	-2.57
General Motors	-9.5596	-3.46	-2.88	-2.57
none				
Volkswagen	-9.1847	-2.58	-1.95	-1.62
Toyota	-6.7759	-2.58	-1.95	-1.62
Hyundai	-10.3718	-2.58	-1.95	-1.62
Ford	-10.4218	-2.58	-1.95	-1.62
General Motors	-9.5623	-2.58	-1.95	-1.62

2.2.2.4 Estimarea modelului statistic de serii de timp pentru prețul de închidere al companiei Volkswagen

În cele ce urmează voi estima și alege cel mai optim model de serii de timp pentru a prognoza prețurile de închidere pe 24 de luni pentru fiecare companie, începând cu Volkswagen. Corelograma seriei diferențiate mă ajută să estimez lag-uri maxime pentru estimarea modelelor ARIMA și SARIMA. Analizând graficul PACF, pot observa că lag-ul maximal pentru componenta AR este 8, iar lag-ul maximal sezonier pentru SAR este 1, datorită faptului că lag-ul 12 este în afara intervalului. Din moment graficul ACF reprezintă aceleași rezultate pentru MA și SMA, voi proceda cu estimările modelelor optime. Pentru a realiza o analiză comparativă între modele, voi estima și pentru ARIMA și pentru SARIMA.




Figure 5 Corelograma seriei diferențiate Volkswagen
Sursa: Analiză proprie, R Studio 4.2.2

Tabela de mai jos reprezintă modele optime rezultate pentru prețul de închidere al companiei Volkswagen: $ARIMA(2,1,1)$ și $SARIMA(1,1,1)(1,0,1)$. Tabela conține rezultatele criteriilor informaționale AIC și BIC, rezultatele erorilor RMSE, MAE și MAPE, și coeficienții pentru fiecare model. Modelul optim ar trebui să aibă toți coeficienții semnificativi și criteriile și erorile minime. În acest caz, modelul SARIMA are coeficienții cu semnificația cea mai mare și are valorile minime pentru AIC și BIC, cât și pentru RMSE, MAE, respectiv MAPE. Rezultă că $SARIMA(1,1,1)(1,0,1)$ este cel mai optim dintre cele două și voi proceda cu analiza modelului pe reziduuri.

Table 4 Modele optime pentru Volkswagen
Sursa: Analiză proprie, R Studio 4.2.2

MODELE ARIMA/ SARIMA	AIC	BIC	RMSE	MAE	MAPE	COEFICIENȚI
ARIMA(2,1,1)	1144.67	1159.92	9.096	6.461	6.866	ar1= -1.084 *** ar2= -0.158 * ma1= 1 *** drift= 0.299
SARIMA(1,1,1)(1,0,1)	1122.01	1137.26	7.985	5.830	6.201	ar1= 0.834 *** ma1=-0.908 *** sar1= 0.513 *** sma1=-0.99 ***

Notă: * : p-value=0.05; **: p-value=0.1 ***: p-value=0.001

Un model bun va produce reziduuri normal distribuite, care nu sunt autocorelate și homoschedastice (au varianța constantă). Pentru verificarea acestor proprietăți, voi executa testul specific fiecărei proprietate. Așa cum reiese din tabel, reziduurile modelului SARIMA nu sunt normal distribuite, deoarece p-value este mai mic decât 0.1, nu există autocorelare și nu prezintă efecte ARCH, p-value fiind mai mare decât 0.1 pentru toate lag-urile analizate. Concluzia este că SARIMA(1,1,1)(1,0,1) este bun pentru a prognoza prețul de închidere al companiei Volkswagen și nu este necesară o ajustare ARCH/GARCH, deoarece reziduurile au varianță constantă.

Table 5 Rezultatele testelor pentru reziduuri pentru Volkswagen
Sursa: Analiză proprie, R Studio 4.2.2

SARIMA(1,1,1)(1,0,1)	Normalizare Jarque-Bera	Autocorelare Ljung-Box	Efect ARCH ARCH-LM
	< 2.2e-16		
Lag 1		0.4615	0.9626
Lag2		0.7619	0.9194
Lag 12		0.9228	0.8134
Lag 24		0.6352	0.9822

2.2.2.5 Estimarea modelului statistic de serii de timp pentru prețul de închidere al companiei Toyota

În cazul companiei Toyota, nu pot spune cu exactitate care ar fi lag-urile maxime pentru componentele modelelor ARIMA și SARIMA, deoarece nu există lag-uri care ies în afara intervalului de încredere. Presupunem că lag-urile maxime pentru AR și MA este 9, deoarece sunt cele mai lungi dintre toate lag-urile din ambele componente și pentru SAR și SMA este lag-ul 3.




Figure 6 Corelograma seriei diferențiate Toyota
Sursa: Analiză proprie, R Studio 4.2.2

Datorită numărului mai mare de coeficienți semnificativi puternic și ale valorilor criteriilor și erorilor minime, cu excepție BIC, concluzionez că modelul SARIMA(1,1,1)(1,0,1) este modelul optim pentru prognozarea prețului de închidere pentru Toyota și pot continua cu testarea reziduurilor.

Table 6 Modele optime pentru Toyota
Sursa: Analiză proprie, R Studio 4.2.2

MODELE ARIMA/ SARIMA	AIC	BIC	RMSE	MAE	MAPE	COEFICIENȚI
ARIMA(1,1,1)	341.93	354.13	0.703	0.511	5.634	ar1= -0.950*** ma1= 0.904*** drift = 0.149**
SARIMA(1,1,1) (1,0,1)	339.16	354.51	0.674	0.497	5.445	ar1= 0.999*** ma1= -0.9455*** sar1= 0.773*** sma1= -0.977***

Notă: * : p-value=0.05; **: p-value=0.1 ***: p-value=0.001

Figura de mai jos reprezintă graficele pentru reziduurile modelului SARIMA care exprimă cele 3 proprietăți. Primul grafic descrie varianța acestora și pot spune că nu este constantă, ceea ce rezultă că modelul pare să aibă efect ARCH și seria va fi nevoie de o ajustare de tip ARCH/GARCH. Graficul din stânga jos arată dacă reziduurile sunt autocorelate sau nu. Deoarece lag-urile nu ies din intervalul de încredere, excepție fiind lag-ul 9, reziduurile par să nu fie autocorelate. Ultimul grafic reprezintă histograma reziduurilor iar linia roșie este distribuția normală pe care ar trebui să o respecte histograma. Deoarece există outlieri în grafic, iar distribuția pare să fie platicurtică, vârful fiind deasupra liniei, rezultă că distribuția pare să nu fie normală. În urma executării testelor, concluzionez că reziduurile nu sunt distribuite normal, nu sunt autocorelate și sunt heteroschedastice, ceea ce înseamnă că modelul SARIMA(1,1,1)(1,0,1) va fi ajustat cu ARCH/GARCH.




Figure 7 Graficul reziduurilor modelului optim pentru Toyota
Sursa: Analiză proprie, R Studio 4.2.2

Ajustarea modelului SARIMA s-a făcut cu ARCH(1), deoarece are coeficienți semnificativi, iar testele pentru autocorelare și heteroschedasticitate acceptă ipoteza nulă, deci nu mai este necesar să ajustez cu GARCH sau ARCH(2), întrucât efectul ARCH a dispărut.

Table 7 Ajustare ARCH pentru model SARIMA pentru Toyota
Sursa: Analiză proprie, R Studio 4.2.2

AJUSTARE						
ARCH/GARCH	COEFICIENȚI	J-B	L-B	ARCH LM	AIC	BIC
ARCH(1)	mu= 0.056 omega= 0.263*** alfa1= 0.54**	0.007	0.611	0.366	1.984	2.043

Notă: * : p-value=0.05; **: p-value=0.1 ***: p-value=0.001

2.2.2.6 Estimarea modelului statistic de serii de timp pentru prețul de închidere al companiei Hyundai

Corelograma pentru compania Hyundai semnifică faptul ca lag-urile maxime pentru SAR și SMA este 3 și voi aplica doar modelul SARIMA pentru această serie deoarece doar lag-urile

sezoniere ies din interval. Cel mai optim model este SARIMA(2,1,2)(1,0,1), deoarece are toti coeficienții puternic semnificativi.




Figure 8 Corelograma seriei diferențiate Hyundai
Sursa: Analiză proprie, R Studio 4.2.2

Conform testelor reziduurilor, modelul este bun pentru a prognoza, deoarece toate valorile p ale testelor depășesc pragul de 0.1 cu excepția testului Jarque-Bera. Așadar, pentru Hyundai nu este necesară ajustarea ARCH/GARCH.

2.2.2.7 Estimarea modelului statistic de serii de timp pentru prețul de închidere al companiei Ford

Situația pentru prețul de închidere al companiei Ford este una specială, deoarece numărul potențial de modele optime ARIMA/SARIMA pentru prognoză este de 8, toate modelele având toți coeficienții puternic semnificativi. Deoarece lag-urile maxime sezoniere sunt foarte lungi și ieșite din intervalul de încredere, voi lua doar modele SARIMA, iar un prim criteriu va fi comparația între criteriile informaționale AIC și BIC. Modelul cu cel mai mic AIC este SARIMA(3,1,3)(1,0,1), iar SARIMA(3,1,3)(0,0,1) are cel mai mic BIC. Deoarece primul model SARIMA are cele mai mici RMSE, MAE și MAPE, acesta va fi folosit pentru testarea reziduurilor.

Table 8 Modele optime pentru Ford
Sursa: Analiză proprie, R Studio 4.2.2

MODELE	AIC	BIC	RMSE	MAE	MAPE	COEFICIENȚII
SARIMA (3,1,3)(0,0,1)	343.06	367.46	0.678	0.492	6.468	ar1= -2.454*** ar2= -2.15*** ar3= -0.68*** ma1= 2.519*** ma2= 2.133*** ma3= 0.591*** sma1= -0.443***
SARIMA (3,1,3)(1,0,1)	340.42	367.87	0.634	0.469	6.241	ar1= -2.463*** ar2= -2.167*** ar3= -0.694*** ma1= 2.54*** ma2= 2.181*** ma3= 0.622*** sar1= 0.49*** sma1= -0.999***

Notă: * : p-value=0.05; **: p-value=0.1 ***: p-value=0.001

Testele îmi arată că reziduurile modelului SARIMA(3,1,3)(1,0,1) nu sunt distribuite uniform, nu sunt corelate până în lag-ul 24 și sunt heteroschedastice, ceea ce înseamnă că voi ajusta modelul utilizând ARCH/GARCH.

Table 9 Rezultatele testelor reziduurilor pentru Ford
Sursa: Analiză proprie, R Studio 4.2.2

SARIMA (3,1,3)(1,0,1)	Normalizare Jarque-Bera	Autocorelare Ljung-Box	Efect ARCH ARCH-LM
	1,216e-06		
Lag1		0.852	0.017
Lag2		0.913	0.016
Lag 12		0.591	0.051
Lag 24		0.052	0.092

În vederea alegerii ajustării, compar între ARCH(2) și GARCH(1,1), deoarece amândouă captează efectele ARCH și voi alege GARCH(1,1), deoarece acesta are criteriile AIC și BIC minime.

2.2.2.8 *Estimarea modelului statistic de serii de timp pentru prețul de închidere al companiei General Motors*

Cazul prețului de închidere pentru General Motors se aseamănă cu cea a companiei Ford, anume că sunt foarte multe modele cu coeficienți semnificativi, totalul fiind de 8. Dintre aceste 8, aleg doar modelele SARIMA pentru că seria prezintă lag-uri sezoniere mari, iar modelul cu cel mai mic AIC este SARIMA(3,1,3)(0,1,2) și modelul cu cel mai mic BIC este SARIMA(2,1,2)(1,1,1). Analizând erorile RMSE, MAE și MAPE ajung la concluzia că primul model menționat este cel pe care îl voi folosi pentru testarea reziduurilor.




Figure 9 Corelograma seriei diferențiate General Motors
Sursa: Analiză proprie, R Studio 4.2.2

Table 10 Modele optime General Motors
Sursa: Analiză proprie, R Studio 4.2.2

MODELE SARIMA	AIC	BIC	RMSE	MAE	MAPE	COEFICIENȚII
SARIMA (2,1,2)(1,1,1)	698.51	719.3	2.289	1.71	6.235	ar1= 1.599*** ar2= -0.934*** ma1= -1.679*** ma2= 0.999*** sar1= -0.5*** sma1= -0.735***
SARIMA (3,1,3)(0,1,2)	698.24	724.97	2.239	1.625	5.966	ar1= -0.532*** ar2= 0.346*** ar3= 0.894*** ma1= 0.507*** ma2= -0.507*** ma3= -0.999*** sma1= -1.152*** sma2= 0.359

Notă: * : p-value=0.05; **: p-value=0.1 ***: p-value=0.001

Analizând graficul reziduurilor și testele pentru verificarea proprietăților, modelul SARIMA(3,1,3)(0,1,2) este un model optim pentru prognoză, deoarece reziduurile nu prezintă autocorelare și au varianța constantă în primele lag-uri, singurul minus fiind faptul ca acestea nu sunt distribuite uniform. Așadar, modelul nu are nevoie de ajustare ARCH/GARCH, efectul ARCH nefiind prezent.

2.2.3 Prognoza indicilor de piață ale companiilor utilizând modelele optime identificate

În această secțiune, voi realiza prognoza indicilor de piață pentru cele cinci companii auto pe o perioadă de 24 de luni. Prognoza se va baza pe modelele de serii de timp optime identificate pentru fiecare, folosind tehnici de modelare și ajustare pentru a capta cât mai precis tendințele și sezonabilitatea datelor istorice.

Pentru Volkswagen AG, modelul optim identificat este SARIMA(1,1,1)(1,0,1), iar prognoza este prezentă în graficul de mai jos. Aceasta arată o stabilizare a prețului, cu fluctuații minore, sugerând că modelul anticipează o perioadă de relativă stabilitate fără fluctuații majore, prețul rămânând în jurul valorii de 100 EUR. Modelul SARIMA include o componentă sezonieră anuală, ceea ce sugerează că prețul poate avea fluctuații sezoniere anuale. În prognoză, aceste fluctuații sunt prezente, dar sunt mici, indicând că sezonabilitatea nu este puternică în datele istorice recente. Alegerea modelului a fost adecvată pentru a capta atât componentele autoregresive, de medie mobilă, cât și sezonabilitatea. Prognoza poate fi utilă pentru planificarea și luarea deciziilor strategice în contextul investițiilor pe termen scurt.




Figure 10 Proгноza finală pentru Volkswagen
Sursa: Analiză proprie, R Studio 4.2.2

Prețul acțiunii companiei Toyota Motor Company va fi prognozat utilizând un model SARIMA(1,1,1)(1,0,1) ajustat cu ARCH(1), cu graficul de mai jos evidențiind prognoza rezultată, Modelul a captat trend-ul ascendent pe care prețul companiei îl avea în datele originale, iar rezultatul este o continuare a acestei tendințe, cu o creștere constantă și treptată până în ianuarie 2026, unde prețul pare să treacă de pragul de 30 EUR începând cu 2025. Această predicție arată o perspectivă pozitivă și stabilă pentru investitorii în acțiuni Toyota, sugerând ca prețurile vor continua să crească în mod constant în următorii doi ani, în ciuda posibilelor fluctuații pe termen scurt.



Figure 11 Proгноза finală pentru Toyota
Sursa: Analiză proprie, R Studio 4.2.2

Următorul grafic ilustrează prognoza evoluției prețului acțiunilor Hyundai Motor Company utilizând modelul SARIMA(2,1,2)(1,0,1). Prognoza sugerează o ușoară tendință descendentă a prețului acțiunilor în următorii doi ani, cu prețul scăzând de la aproximativ 130 EUR în februarie 2024 la sub 115 EUR în ianuarie 2026. Deși există o tendință generală, prețul este prognozat să fluctueze moderat pe parcursul perioadei de prognoză, reflectând sezonabilitatea. Spre sfârșitul perioadei, prețul pare să își continue panta ascendentă, fluctuațiile rămânând prezente. Prognoza este esențială pentru investitori și manageri, oferind o perspectivă asupra performanței viitoare a companiei.




Figure 12 Proгноза finală pentru Hyundai
Sursa: Analiză proprie, R Studio 4.2.2

Proгноза prețului de închidere pentru Ford Motor Company s-a făcut utilizând modelul SARIMA(3,1,3)(1,0,1), ajustat cu GARCH(1,1). Rezultatul este unul asemănător cu cel al prețului Hyundai, unde trend-ul este descendent, prețul ajungând de la 10,5 EUR la începutul anului 2024 la sub 9 EUR în februarie 2026, cu mici fluctuații la mijloc. Trend-ul pare sa continue sa fie descrescător, ceea ce poate le îndemna investitorilor o prudență în ceea ce privește prețul acțiunilor companiei.




Figure 13 Proгноза finală pentru Ford
Sursa: Analiză proprie, R Studio 4.2.2

Modelul SARIMA(3,1,3)(0,1,2) a fost utilizat pentru a prognoza prețul acțiunilor General Motors Company. Conform prognozei, prețul este anticipat să continue tendința de creștere moderată. La începutul perioadei de prognoză, în februarie 2024, prețul este estimat la 35 EUR și este proiectat să crească lent, cu fluctuații minore, până la aproximativ 42 EUR la sfârșitul perioade de prognoză, în ianuarie 2026, unde pare să se stabilizeze. Această tendință evidențiază evoluția istorică și prognoza prețului acțiunilor General Motors Company și le oferă investitorilor o perspectivă asupra performanței viitoare a companiei.




Figure 14 Proгноза флналэ pentru General Motors
Sursa: Analizэ proprie, R Studio 4.2.2

2.2.4 Limitări și recomandări

Limitările cercetării ar trebui luate în considerare pentru a înțelege mai bine contextul și validitate rezultatelor obținute. O recomandare ar fi introducerea a mai multor companii din industria auto în analiză. Companii precum Mercedes-Benz, Honda, Tesla sau Stellantis pot face ca industria auto să fie explicată mult mai aprofundat.

Datele operaționale, cum ar fi numărul de vehicule vândute, veniturile, costurile și profiturile, au fost colectate din rapoartele anuale ale companiilor pentru perioada 2000-2023. Recomandarea este să se adune și să se utilizeze detaliile suplimentare pentru a extinde perioada de analiză și pentru ca statistica descriptivă să fie mult mai complexă, aplicându-se pe un număr mai mare de date.

În ceea ce privește prețurile de închidere, datele istorice încep din 2011 în urma reîntrării pe piața bursieră în 2010 a companiei General Motors după falimentul și restructurarea sa (2011). Identificarea datelor istorice de dinainte de faliment, utilizarea de proxy-uri sau înlocuirea cu alta companie precum Honda ar putea îmbunătăți validitatea rezultatelor.

În această lucrare, modelele de prognoză alese – ARIMA/SARIMA și ajustările ARCH/GARCH nu au reziduurile distribuite uniform. Analiza reziduurilor este crucială pentru validarea modelului, de aceea reziduurile ar trebui să fie distribuite normal, alături de lipsa autocorelării și varianța constantă. Modelele actuale ar putea avea limitări în ceea ce privește

captarea volatilității și a sezonității complete din datele analizate. Recomandarea ar fi considerarea de metode alternative de prognoză care să asigure reziduuri distribuite normal. Utilizarea de modele mai avansate, cum ar fi modelele de Machine Learning și Deep Learning, așa cum s-a făcut într-un studiu menționat anterior (ArunKumar, et al., 2022), poate oferi prognoze mai precise. De exemplu, metodele precum Rețele Neuronale Recurente (RNN) sau Long Short-Term Memory (LSTM) pot captura relațiile complexe și nelineare din date.

Concluzii

Această lucrare de licență a avut ca obiectiv principal analiza și prognoza performanțelor financiare și operaționale ale cinci companii autor majore: Volkswagen AG, Toyota Motor Corporation, Hyundar Motor Company, Ford Motor Company și General Motors Company. Am utilizat atât metode de statistică descriptivă pentru a evalua vânzările de vehicule, veniturile, costurile și profiturile, cât și modele de serii de timp pentru a prognoza prețurile acțiunilor acestor companii.

Prin utilizarea statisticii descriptive, am obținut o perspectivă detaliată asupra variațiilor și tendințelor istorice ale indicatorilor financiari și operaționali. Am identificat valori minime și maxime, media, mediana, abaterea standard, coeficientul de variație, coeficienții de asimetrie și boltire pentru fiecare companie. De exemplu, am observat că General Motors și Toyota au avut cele mai mari vânzări medii anuale, în timp ce Hyundai a prezentat o variabilitate relativ stabilă a veniturilor.

În ceea ce privește prognoza prețurilor acțiunilor, am folosit modele de serii de timp optimizate pentru fiecare companie. Am observat că modelul utilizat este SARIMA pentru toate companiile, pentru a capta cât mai bine puținele tendințe sezoniere rămase, iar pentru Toyota și Ford a fost nevoie de o ajustare GARCH pentru a capta volatilitatea varianței reziduurilor.

Metodele aplicate în această lucrare au demonstrat eficiența combinării statisticii descriptive cu modelele de serii de timp pentru analiza și prognoza datelor financiare complexe. În plus, recomandarea de a explora metode avansate de Machine Learning și Deep Learning, cum ar fi RNN și LSTM, subliniază importanța adoptării tehnologiilor moderne pentru îmbunătățirea acurateței prognozelor.

Lucrarea prezintă câteva limitări, în special legate de insuficiența datelor pentru anumite companii, cum ar fi General Motors, care a reintrat pe piața bursieră în 2010, iar datele disponibile încep doar din 2011. De asemenea, modelele de serii de timp utilizate nu au reziduurile distribuite uniform, ceea ce poate afecta validitatea prognozelor. Recomand colectarea de date suplimentare și explorarea metodelor avansate de Machine Learning și Deep Learning pentru a obține prognoze mai precise.











Bibliografie











1. ArunKumar, K. E. et al., 2022. Comparative analysis of Gated Recurrent Units (GRU), long Short-Term memory (LSTM) cells, autoregressive Integrated moving average (ARIMA), seasonal autoregressive Integrated moving average (SARIMA) for forecasting COVID-19 trends. *Alexandria Engineering Journal*, 61(10), pp. 7585-7603.
2. Brooks, C., 2008. *Introductory Econometrics for Finance*. 2nd ed. s.l.:Cambridge University Press.
3. Chapman, C. & Feit, E. M., 2015. *R for Marketing Research and Analytics*. s.l.:Springer.
4. Cowpertwait, P. S. & Metcalfe, A. V., 2009. *Introductory Time Series with R*. s.l.:Springer.
5. Ford Motor Company, 2001. *Form 10-K (Annual Report)*, s.l.: Ford Motor Company.
6. Ford Motor Company, 2007. *2006 Annual Report*, s.l.: Ford Motor Company.
7. Ford Motor Company, 2009. *2008 Annual Report*, s.l.: Ford Motor Company.
8. Ford Motor Company, 2014. *2013 Annual Report*, s.l.: Ford Motor Company.
9. Ford Motor Company, 2016. *2015 Annual Report*, s.l.: Ford Motor Company.
10. Ford Motor Company, 2022. *2021 Annual Report*, s.l.: Ford Motor Company.
11. General Motors Company, 2011. *2010 Annual Report*, s.l.: General Motors Company.
12. General Motors Company, 2013. *Form 10-K*, s.l.: General Motors Company.
13. General Motors Company, 2017. *Form 10-K*, s.l.: General Motors Company.
14. General Motors Company, 2023. *Form 10-K*, s.l.: General Motors Company.
15. Grant, A., Ries, R. & Thompson, C., 2016. Quantitative Approaches in Life Cycle Assessment – Part I – Descriptive Statistics and Factor Analysis. *International Journal of Life Cycle Assessment*, 21(6), pp. 903-911.
16. Güngör, B. O., Ertugrul, H. M. & Soytaş, U., 2021. Impact of Covid-19 Outbreak on Turkish Gasoline Consumption. *Technological Forecasting and Social Change*, Volume 166.
17. Hussin, N. H., Yusof, F., Jamaludin, A. R. & Norrulashikin, S. M., 2021. Forecasting Wind Speed in Peninsular Malaysia: An Application of ARIMA and ARIMA-GARCH Models. *Pertanika Journal of Science and Technology*, 29(1), pp. 31-58.
18. Hyundai Motor Company, 2001. *2000 Annual Report*, s.l.: Hyundai Motor Company.
19. Hyundai Motor Company, 2009. *2008 Annual Report*, s.l.: Hyundai Motor Company.
20. Hyundai Motor Company, 2016. *Annual Report 2015*, s.l.: Hyundai Motor Company.
21. Hyundai Motor Company, 2017. *Annual Report 2016*, s.l.: Hyundai Motor Company.








22. Lee, J.-Y., Nguyen, T.-T., Nguyen, H.-G. & Lee, J.-Y., 2022. Towards Predictive Crude Oil Purchase: A Case Study in the USA and Europe. *Energies*, 15(11).
23. Modise, R. K., Mpofu, K. & Adenuga, O. T., 2021. Energy and Carbon Emission Efficiency Prediction: Applications in Future Transport Manufacturing. *Energies*, 14(24).
24. Perone, G., 2022. Using the SARIMA Model to Forecast the Fourth Global Wave of Cumulative Deaths from COVID-19: Evidence from 12 Hard-Hit Big Countries. *Econometrics*, 10(2).
25. Salvatore, D. & Reagle, D., 2002. *Schaum's Outline of Theory and Problems of Statistics and Econometrics*. 2nd ed. s.l.:McGraw-Hill.
26. Sirisha, U. M., Belavagi, M. C. & Attigeri, G., 2022. Profit Prediction Using ARIMA, SARIMA and LSTM Models in Time Series Forecasting: A Comparison. *IEEE Access*, Volume 10, pp. 124715-124727.
27. Tan, C. V. et al., 2022. Forecasting COVID-19 Case Trends Using SARIMA Models during the Third Wave of COVID-19 in Malaysia. *International Journal of Environmental Research and Public Health*, 19(3).
28. Toppur, B., Thomas, T., González-Tejero, C. B. & Gavrila, S., 2023. Forecasting Commercial Vehicle Production Using Quantitative Techniques. *Contemporary Economics*, 17(1), pp. 10-23.
29. Toyota Motor Corporation, 2010. *Annual Report 2010*, s.l.: Toyota Motor Corporation.
30. Toyota Motor Corporation, 2016. *Financial Summary FY2016*, s.l.: Toyota Motor Corporation.
31. Toyota Motor Corporation, 2021. *Integrated Report 2021*, s.l.: Toyota Motor Corporation.
32. Toyota Motor Corporation, 2024. *Financial Summary FY2024*, s.l.: Toyota Motor Corporation.
33. Trull, O., García-Díaz, J. C. & Peiró-Signes, A., 2021. Forecasting Irregular Seasonal Power Consumption. An Application to a Hot-Dip Galvanizing Process. *Applied Sciences-Basel*, 11(1).
34. Vargas, C. & Cortés, M., 2017. Automobile spare-parts forecasting: A comparative study of time series methods. *International Journal of Automotive and Mechanical Engineering*, 14(1), pp. 3898-3912.
35. Volkswagen AG, 2003. *Annual Report 2002*, s.l.: Volkswagen AG.
36. Volkswagen AG, 2009. *Annual Report 2008*, s.l.: Volkswagen AG.
37. Volkswagen AG, 2012. *Annual Report 2011*, s.l.: Volkswagen AG.
38. Volkswagen AG, 2016. *Annual Report 2015*, s.l.: Volkswagen AG.
39. Volkswagen AG, 2020. *Annual Report 2019*, s.l.: Volkswagen AG.
40. Volkswagen AG, 2022. *Annual Report 2021*, s.l.: Volkswagen AG.

41. Wang, H., Tian, C. W., Wang, W. M. & Luo, X. M., 2018. Time-Series Analysis of Tuberculosis from 2005 to 2017 in China. *Epidemiology and Infection*, 146(8), pp. 935-939.
42. Yaziz, S. R., Zakaria, R. & Suhartono, 2019. ARIMA and Symmetric GARCH-type Models in Forecasting Malaysia Gold Price. *2nd International Conference on Applied & Industrial Mathematics and Statistics*, Volume 1366.
43. Zhou, L. et al., 2018. Time Series Model for Forecasting the Number of New Admission Inpatients. *BMC Medical Informatics and Decision Making*, Volume 18.
44. Hyundai Motor Company, 2022. *Hyundai Motor outpaces European automotive market in 2021*. [Online]
Available at: <https://www.hyundai.news/eu/articles/press-releases/hyundai-outpaces-european-automotive-market-in-2021.html>
45. Insider Monkey, 2023. *Top 20 Biggest Car Manufacturers by 2023 Revenue*. [Online]
Available at: <https://www.insidermonkey.com/blog/top-20-biggest-car-manufacturers-by-2023-revenue-1206908/>
46. Yahoo Finance, Available at: <https://finance.yahoo.com/>
47. R
48. R Studio


Anexă









Corelograma prețului Toyota




Corelograma prețului Hyundai




Corelograma prețului Ford






Corelograma prețului General Motors







Toyota SARIMA(1,1,1)(1,0,1)	Normalizare Jarque-Bera 1.098e-10	Autocorelare Ljung-Box	Efect ARCH ARCH-LM
Lag 1		0.655	0.083
Lag 2		0.582	0.004
Lag 12		0.42	6.306e-05
Lag 24		0.757	3.307e-05







Hyundai SARIMA(2,1,2)(1,0,1)	Normalizare Jarque-Bera 0.005	Autocorelare Ljung-Box	Efect ARCH ARCH-LM
Lag 1		0.451	0.107
Lag 2		0.447	0.129
Lag 12		0.877	0.894
Lag 24		0.984	0.92





AJUSTARE ARCH/GARCH	ARCH					
	COEFICIENȚI	J-B	L-B	LM	AIC	BIC
ARCH(2)	mu= 0.048 omega= 0.231*** alfa1= 0.294* alfa2= 0.143	0.042	0.651	0.127	1.87	1.948
GARCH(1,1)	mu= 0.043 omega= 0.008 alfa1= 0.095* beta1= 0.897***	0.108	0.522	0.571	1.805	1.883



General Motors SARIMA(3,1,3)(0,1,2)	Normalizare Jarque-Bera 2.531e-08	Autocorelare Ljung-Box	Efect ARCH ARCH-LM
Lag 1		0.674	0.591
Lag 2		0.846	0.47
Lag 12		0.957	0.004
Lag 24		0.763	0.01

Listă Figuri

Figure 1 Evoluția fiecărei companii în funcție de obiectivele alese Sursa: Analiză proprie, R Studio 4.2.2	15
Figure 2 Evoluția prețurilor acțiunilor Sursa:Analiză proprie, R Studio 4.2.2	18
Figure 3 Identificarea sezonalityi fiecărui preț Sursa:Analiză proprie, R Studio 4.2.2	19
Figure 4 Corelograma seriei Volkswagen Sursa:Analiză proprie, R Studio 4.2.2	20
Figure 5 Corelograma seriei diferențiate Volkswagen Sursa:Analiză proprie, R Studio 4.2.2.....	23
Figure 6 Corelograma seriei diferențiate Toyota Sursa:Analiză proprie, R Studio 4.2.2	25
Figure 7 Graficul reziduurilor modelului optim pentru Toyota Sursa:Analiză proprie, R Studio 4.2.2.....	27
Figure 8 Corelograma seriei diferențiate Hyundai Sursa:Analiză proprie, R Studio 4.2.2.....	28
Figure 9 Corelograma seriei diferențiate General Motors Sursa:Analiză proprie, R Studio 4.2.2.....	30
Figure 10 Prognoza finală pentru Volkswagen Sursa:Analiză proprie, R Studio 4.2.2	32
Figure 11 Prognoza finală pentru Toyota Sursa:Analiză proprie, R Studio 4.2.2.....	33
Figure 12 Prognoza finală pentru Hyundai Sursa:Analiză proprie, R Studio 4.2.2	34
Figure 13 Prognoza finală pentru Ford Sursa:Analiză proprie, R Studio 4.2.2	35
Figure 14 Prognoza finală pentru General Motors Sursa:Analiză proprie, R Studio 4.2.2.....	36

Listă Tabele

Table 1 Rezultatele statisticilor descriptive pentru fiecare companie Sursa: Analiză proprie, R Studio 4.2.2	14
Table 2 Rezultatele testului ADF pentru seriile nediferențiate Sursa:Analiză proprie, R Studio 4.2.2.....	21
Table 3 Rezultatele testului ADF pentru seriile diferențiate de ordin 1 Sursa:Analiză proprie, R Studio 4.2.2	22
Table 4 Modele optime pentru Volkswagen Sursa:Analiză proprie, R Studio 4.2.2	24
Table 5 Rezultatele testelor pentru reziduuri pentru Volkswagen Sursa: Analiză proprie, R Studio 4.2.2.....	24
Table 6 Modele optime pentru Toyota Sursa:Analiză proprie, R Studio 4.2.2.....	26
Table 7 Ajustare ARCH pentru model SARIMA pentru Toyota Sursa:Analiză proprie, R Studio 4.2.2.....	27
Table 8 Modele optime pentru Ford Sursa:Analiză proprie, R Studio 4.2.2.....	29
Table 9 Rezultatele testelor reziduurilor pentru Ford Sursa:Analiză proprie, R Studio 4.2.2	29

Table 10 Modele optime General Motors Sursa:Analiză proprie, R Studio 4.2.2	31
---	----